



Predstavitev naloge


MERITEV



NAPOVED ELASTIČNIH KONSTANT REALNEGA VZORCA




NUMERIČNA SIMULACIJA



UPORABA:

- Nekako (tipično s pulzem električnega polja) v nematski celici ustvarimo neravnovesno začetno konfiguracijo direktorja $\mathbf{n}(z, t = 0)$.
- Potem se $\mathbf{n}(z, t)$ s časom rekonfigurira proti ravnovesnemu stanju $\mathbf{n}(z, t \rightarrow \infty)$, ob tem pa se spreminja intenziteta prepuščene svetlobe $I(t)$.
- Iz izmerjene $I(t)$ z nevronske mreže prepoznamo elastične konstante.
- Prej je treba nevronske mreže naučiti opravljati to nalogo. Naučimo jo na številnih učnih parih, kjer je **vhodni vektor** nevronske mreže $\mathbf{X} = [I_{t=0}, I_{t=\Delta t}, \dots, I_{t=399\Delta t}]$, pričakovan izhodni vektor pa $\mathbf{Y} = [K]$ (v enokonstantnem približku – 1. del naloge), oziroma $\mathbf{Y} = [K_{11}, K_{33}]$ (če napovedujemo obe konstanti – 2. del naloge)
- Učne pare pridobimo tako, da:
 1. Izžrebamo naključno/-i elastično/-i konstanto/-i z nekega smiselnega intervala $[0, K_{max}]$
 2. Generiramo gladko naključno začetno stanje direktorja, opisano s $\theta(z, t = 0)$.
 3. Simuliramo relaksacijsko dinamiko s $\theta(z, t)$
 4. Simuliramo transmisijo svetlobe $I(t)$.

Predstavitev naloge



1. Parametrizacija direktorja

$$\mathbf{n}(z) = (n_x, 0, n_z) = (\cos \theta(z), 0, \sin \theta(z))$$

2. Elastična prosta energija:

$$f_{FO} = \frac{K_{11}}{2} \left(\frac{\partial n_z}{\partial z} \right)^2 + \frac{K_{33}}{2} \left(\frac{\partial n_x}{\partial z} \right)^2$$

3. Relaksacijska dinamika

$$\frac{d}{dz} \left[\frac{\partial f_{FO}}{\partial \left(\frac{\partial \theta}{\partial z} \right)} \right] - \frac{\partial f_{FO}}{\partial \theta} = \gamma_1 \frac{\partial \theta}{\partial t}$$



$$\frac{\partial^2 \theta}{\partial z^2} (K_{11} \cos^2 \theta + K_{33} \sin^2 \theta) + \frac{K_{33} - K_{11}}{2} \left(\frac{\partial \theta}{\partial z} \right)^2 \sin 2\theta = \gamma_1 \frac{\partial \theta}{\partial t}$$

Če je $K_{11} = K_{33} = K$ (**prvi del naloge**):

$$K \frac{\partial^2 \theta}{\partial z^2} = \gamma_1 \frac{\partial \theta}{\partial t}$$



Predstavitev naloge

MERITEV





Predstavitev naloge

MERITEV





Predstavitev naloge

MERITEV





Predstavitev naloge

MERITEV





Predstavitev naloge

MERITEV





Predstavitev naloge

MERITEV



Predstavitev naloge

MERITEV



Uporaba skript za pripravo učnih podatkov – 2.del

- Učne podatke, oz. program za generiranje, dobite na Marvinu v `/data/PSUF_naloge/3-naloga/`
- V svojo mapo `/home/ime` si skopirajte `DataGeneration.py` in podatke lahko generirate sami:

generiranje_podatkov.py

```
import numpy as np
import os

from DataGeneration import GenerateData

obj = GenerateData(
    D=10 * 1e-6,      # debelina celice
    n_o0=1.545,       # lomni kolicnik no
    n_e0=1.740,       # lomni kolicnik ne
    K_max=20,         # el. konst. zrebamo z intervala [0, K_max] v enotah pN
    rot_visc=0.000,   # rotacijska viskoznost gamma1
    no_constants=2,   # stevilo razlicnih elasticnih konstant (1 ali 2)
)

obj.generate(
    n=1000,           # stevilo generiranih parov
    f0=0,             # kot sidranja pri z=0 [rad]
    f1=0,             # kot sidranja pri z=D [rad]
    lbd=[400],         # tabela valovnih dolzin svetlobe v nm, za katere racunamo transmisijo
)

# izvoz podatkov
obj.export(add_intensity_noise=0)
obj.export(add_intensity_noise=0.01) # vrednost "add_intensity_noise" je stand. dev. belega suma, ki ga pristejemo I(t)
obj.export(add_intensity_noise=0.1)
obj.export(add_intensity_noise=0.2)
```

0100
0010
1001
0110
DataK_
meta.dat

0100
0010
1001
0110
intensity40
Onoise10.
npz

0100
0010
1001
0110
intensity40
Onoise100.
npz

0100
0010
1001
0110
intensity40
Onoise200.
npz

0100
0010
1001
0110
Kvalues.npz

0100
0010
1001
0110
theta0.npz

Te parametre lahko pustite nespremenjene, razen v 2. delu naloge bo `no_constants=2`.

Za imitacijo eksperimenta: 505 nm

Izgradnja nevronske mreže – 2. del

```
from sklearn.model_selection import GridSearchCV
from tensorflow.keras.wrappers.scikit_learn import KerasRegressor
from tensorflow.keras import Sequential
from tensorflow.keras.layers import Dense
from tensorflow.keras.callbacks import ReduceLROnPlateau
from tensorflow.keras import optimizers

# To bomo rabili za GridSearch optimalnih parametrov
# wrapper za Keras model v sklearn
# Sequential je tip nevronske mreže
# Dense je gosto-povezana plast, kjer so povezani vsi nevroni iz sosednjih plasti
# Metoda za zmanjševanje learning rate-a, ko se učenje začne ustavljati
# Optimizatorji

model = Sequential()
model.add(Dense(200, activation='sigmoid', input_shape=(400,))) # ustvari nevronska mrežo
# prva skrita plast: 200 nevronov, 400 vhodnih nevronov
model.add(Dense(100, activation='sigmoid')) # dodamo še ostale skrite plasti (tukaj le še ena, potencialno lahko več)
model.add(Dense(2, activation='relu')) # zadnja plast je izhodna, ker iščemo skalar, vsebuje samo en nevron


model.compile(optimizer=optimizers.Adam(learning_rate=5e-4), loss="mean_absolute_error", metrics=["mean_squared_error"])
# loss je tista cenilka, ki jo bo algoritem minimiziral
# metrics pa bo samo informativno izračunal in shranil kot output

history = model.fit(X_train, Y_train, epochs=50, batch_size=25, validation_data=(X_test, Y_test), shuffle=True)
# shuffle - mešanje podatkov pred vsako epoko
```


Navodila naloge – 2. del

7. V mapah "DataK13*" se nahajajo simulacijski rezultati za 1.2 sekund trajajočo relaksacijo z obema elastičnima konstantama, K_{11} in K_{33} , pri različnih kombinacijah sidranja (planarno-planarno, planarno-homeotropno, homeotropno-homeotropno). Sestavite nevronsko mrežo za prepoznavanje obeh konstant ter preverite, pri kakšnih robnih pogojih lahko dobro napovemo posamezno konstanto. Zakaj je napoved v določenih primerih slaba?



Smer
sidranja
(a)



(b)



(c)



Preverite oblike
intenzitet $I(t)$!



DataK13_pp



DataK13_hh



DataK13_ph

Navodila naloge – 2. del

8. V mapi "/ExpData" lahko najdete 30 izmerjenih intenzitetnih krivulj za vzorec tekočega kristala 5CB na časovnem intervalu $[0 \text{ s}, 1.95 \text{ s}]$ v 15600 časovnih točkah:

`(time=np.linspace(0,1.95,15600)).`

Uporabljena je bila celica debeline $10\mu\text{m}$, kombinacija planarnega in homeotropnega sidranja ter svetilo z valovno dolžino $\lambda = 505 \text{ nm}$. Pri sobni temperaturi je rotacijska viskoznost za 5CB $\gamma_1 = 0.098 \text{ Pa s}$, lomna količnika pa sta $n_o = 1.545$, $n_e = 1.740$, kar je že upoštevano v generiranih numeričnih podatkih.

Če niste spreminjali parametrov v generatorju podatkov ali če uporabljate že generirane podatke, potem nevronska mreža za vhodni podatek pozna izmerjeno intenziteto $I(t)$, ki je diskretizirana v 400 časovnih točkah na intervalu $[0 \text{ s}, 1.2 \text{ s}]$. Da eksperimentalne meritve preoblikujete v format, ki je kompatibilen z nevronske mreže, si lahko pomagata z interpolacijo (funkcija **interp1d** iz knjižnice *scipy*). Poskusite z generiranimi podatki naučiti nevronske mreže tako, da bodo napovedi na eksperimentalnih podatkih čim boljše. Kako izbira hiperparametrov vpliva na porazdelitev napovedi elastičnih konstant vzorca? V resnici sta pri sobni temperaturi elastični konstanti $K_{11} \approx 6.6 \text{ pN}$ in $K_2 \approx 9.0 \text{ pN}$ [7]. Eksperimentalne rezultate je pripravil izr. prof. dr. Miha Škarabot iz IJS, Odsek F5.

Navodila naloge – 2. del

9. Za izboljšanje rezultatov lahko poskusite pridobiti "več meritev" s tem, da iz posamezne izmerjene intenzitetne krivulje vzamete več intervalov z različnimi začetnimi časi. Premislite, zakaj je tak pristop smiseln. Kako se pri tem spremeni napoved elastičnih konstant?
10. (* Dodatno) Inicializacija uteži posamezne nevronske mreže je pred vsakim učenjem nključna, zato tudi mreže z identično arhitekturo in z uporabo istih učnih hiperparametrov po koncu učenja delujejo nekoliko drugačne. Ali opazite izboljšanje napovedi, če elastične konstante napoveste z ansamblom (petih, desetih ali še več) nevronskih mrež in rezultate potem povprečite?